รายงานโครงงานสัมมนา

Phish Radar AI

เจาะลึกสถาปัตยกรรม ชุดข้อมูล และผลเปรียบเทียบอัลกอริทึม

ทฤษฎีและงานวิจัยอ้างอิง

รากฐานการพัฒนาแบบจำลอง

Ma et al. (2009)

สกัดคุณลักษณะจาก URL โดยตรง

Sahingoz et al. (2019)

Random Forest ให้ผลแม่นยำที่สุด

Dalton et al. (2025)

เน้นลดความคล้ายของข้อมูลข้ามชุด

การเตรียมข้อมูล

แหล่งข้อมูลและการจัดการความเอนเอียง

925,602

ยอดรวมแถวข้อมูลพัฒนา

- PhreshPhish v1.0.1
- URL-Phish v1
- DeepURLBench
- UCI PhiUSIIL 2024
- Web page phishing detection

การล้างข้อมูลซ้ำซ้อน

ตัด Canonical URL และแยกป้ายกำกับขัดแย้ง

การแบ่งชุดข้อมูล (Split)

จัดกลุ่มตาม Registered Domain ป้องกันข้อมูลรั่วไหล

การสกัดคุณลักษณะ (FEATURE EXTRACTION)

แปลง URL เป็นเวกเตอร์ 174 ตัวแปร

128

Hashed n-grams

รูปแบบกลุ่มอักขระในโดเมน

32

โครงสร้าง URL

ความยาวและสัดส่วนอักขระ

9

บริบทโดเมน

ลักษณะการใช้โดเมนย่อย

5

พารามิเตอร์อื่นๆ

สัญญาณคำและบริบทต้นทาง

สมการหลัก

การคำนวณและปรับเทียบความเสี่ยง

1. Random Forest (ค่าเฉลี่ยต้นไม้ตัดสินใจ)

$$p_{RF}(x) = \frac{1}{T} \sum_{t=1}^{T} p_t(y = 1 \mid x)$$

2. Probability Calibration (Platt Scaling)

$$p_{cal}(x) = \frac{1}{1 + \exp[-(a \cdot p_{RF}(x)}$$

นำค่า p_{cal} คูณ 100 เพื่อแปลงเป็นคะแนนความเสี่ยง

ตัวชี้วัดประสิทธิภาพ

สมการประเมินความแม่นยำ

Recall (ความครอบคลุม)

$$\frac{TP}{TP + FN}$$

สัดส่วนฟิชชิงจริงที่ตรวจพบ

FPR (อัตราเตือนผิด)

$$\frac{FP}{FP + TN}$$

สัดส่วนเว็บปกติที่ถูกบล็อก

Precision (ความแม่นยำ)

$$\frac{TP}{TP + FP}$$

สัดส่วนฟิชชิงในกลุ่มที่ระบบแจ้ง

ผลทดสอบชุดข้อมูลยืนยัน

ผลประเมินบนชุด Confirmation

ชุดข้อมูล	เกณฑ์คะแนน	Recall	FPR	Precision
PhiUSIIL	60 (แจ้งเตือน)	34.48%	4.36%	74.30%
PhiUSIIL	80 (ปิดกั้น)	26.68%	1.64%	85.59%
DeepURLBench	60 (แจ้งเตือน)	58.72%	17.74%	76.80%
DeepURLBench	80 (ปิดกั้น)	43.82%	10.38%	80.85%

โครงสร้างแบบจำลอง

การตั้งค่า Random Forest และ MLP

Random Forest

- จำนวน 120 ต้น (Trees)
- ความลึกสูงสุด (Max Depth) = 20
- ตัวแปรเข้า: 172 คุณลักษณะดิบ
- ไม่มีการถ่วงน้ำหนักคลาส (Class Weighting)

Deep Learning (MLP)

- 3 Hidden Layers (128 → 64 → 32 → 1)
- ฟังก์ชันกระตุ้น ReLU และ Sigmoid
- Dropout 0.15 ลด Overfitting
- Optimizer: AdamW (Learning Rate 0.001)

ผลการทดลอง (COLAB DEMO)

เปรียบเทียบ RF กับ Deep Learning

ตัวชี้วัด (Threshold 0.50)	Random Forest	Deep Learning (MLP)	ผู้ชนะ / ความหมาย
Average Precision (AP)	0.8914	0.8734	RF จัดอันดับความเสี่ยงดีกว่า
Recall (การตรวจพบ)	66.30%	74.64%	MLP จับฟิชชิงได้ครอบคลุมกว่า
FPR (อัตราเตือนผิด)	4.20%	8.73%	RF รบกวนผู้ใช้น้อยกว่า
CPU Latency (Median)	6.31 ms	0.22 ms	MLP ประมวลผลเร็วกว่ามาก

การทำงานร่วมกันของระบบ

กระบวนการตรวจสอบและอธิบายผล



1. Client

ส่วนขยายเบราว์เซอร์รับ URL



2. FastAPI Backend

สกัดคุณลักษณะ 174 ตัวแปร



3. Random Forest

ทำนายความเสี่ยง 0-100



4. LLM (Ollama)

เรียบเรียงคำอธิบายผลลัพธ์

ข้อจำกัดและข้อเสนอแนะ

ความท้าทายและแนวทางพัฒนาต่อ

1. ขอบเขตโมเดล

วิเคราะห์เฉพาะ URL ไม่ได้ตรวจสอบเนื้อหาภายในหน้าเว็บ

2. ข้อจำกัดชุดข้อมูล

ประเมินบนชุดแบบปิด ยังไม่ใช่ Forward-Temporal Test เต็มรูปแบบ

3. ความเข้าใจผู้ใช้

จำเป็นต้องทดสอบ User Study เพื่อวัดประสิทธิภาพการแจ้งเตือน

Q&A

จบการนำเสนอ

ขอขอบคุณสำหรับการรับฟัง