คำอธิบายสูตรคะแนนความเสี่ยง Phish Radar AI

สรุปตัวแปร ขั้นตอนคำนวณ และตัวอย่างแบบทีละขั้น อ้างอิงค่าที่ใช้อยู่จริงในโปรเจกต์

1. สูตรที่ระบบใช้งานอยู่

FinalScore = 100 x ConsensusGuardrail(LearnedFusion(FuzzyScore, RandomForestScore))

สูตรนี้ไม่ได้คำนวณจากคะแนนเดียว แต่เริ่มจากกฎตรวจ URL และโมเดล Machine Learning จากนั้นรวมผลด้วย Logistic Regression และตรวจเงื่อนไขความเห็นพ้องอีกชั้นหนึ่ง

หมายเหตุ: ในชั้น LearnedFusion ค่า FuzzyScore และ MLScore ถูกปรับให้อยู่ในช่วง 0 ถึง 1 ก่อนคำนวณ ส่วน FinalScore แสดงเป็นช่วง 0 ถึง 100

2. คะแนนต้นทาง

ตัวแปร	คำนวณจากอะไร	ช่วงค่า
RuleScore	กฎตรวจโครงสร้าง URL เช่น IP host, punycode, URL ซ้อน, parameter สำหรับ redirect/credential, คำเสียง และชนิดไฟล์	0-100
FuzzyScore	แปลง RuleScore เป็นสมาชิกกลุ่ม safe, suspicious และ dangerous แล้วหาค่าเฉลี่ยถ่วงน้ำหนัก	0-100
RandomForest Score (MLScore)	ความน่าจะเป็น phishing จาก Random Forest หลังปรับเทียบความน่าจะเป็นแล้ว	0-1 ก่อนคูณเป็นคะแนน

3. การคำนวณ FuzzyScore

สมาชิก Fuzzy ที่ใช้จริงมี 3 กลุ่ม

- safe: เต็มจนถึง RuleScore 20 และลดเหลือศูนย์ที่ 45
- suspicious: รูปสามเหลี่ยม เริ่มที่ 20 สูงสุดที่ 50 และสิ้นสุดที่ 80
- dangerous: เริ่มเพิ่มหลัง 55 และเต็มที่ 85

FuzzyScore = [safe(0) + suspicious(50) + dangerous(100)] / [safe + suspicious + dangerous]

4. LearnedFusion ทีอยู่ในโมเดลปัจจุบัน

ระบบใช้ Logistic Regression รวม FuzzyScore กับ MLScore โดยค่าสัมประสิทธิ์ทีบันทึกในโมเดลปัจจุบันคือ

z = -3.0433 - 0.3361(FuzzyScore) + 6.4386(MLScore)

LearnedFusion = 1 / (1 + exp(-z))

ค่าสัมประสิทธิ์เป็นค่าทีโมเดลเรียนรู้จากข้อมูล ไม่ใช่น้ำหนัก 40/60 ทีกำหนดด้วยมือ โดย FuzzyScore และ MLScore ในสมการนีอยู่ในช่วง 0 ถึง 1

5. ConsensusGuardrail

เงือนไข	ผลลัพธ์ขันต่ำ
FuzzyScore ≥ 0.85 และ MLScore ≥ 0.95	FinalScore = 100 (block consensus)
FuzzyScore ≥ 0.50 และ MLScore ≥ 0.90	FinalScore อย่างน้อย 99 (warning consensus)
ไม่เข้าเงือนไขข้างต้น	ใช้ LearnedFusion x 100

Threshold ของระบบปัจจุบัน: คะแนนต่ำกว่า 96 = allow, ตังแต่ 96 = warn และตังแต่ 100 = block

6. ตัวอย่างโจทย์สมมติ

สมมติให้ตรวจ URL ต่อไปนี (ใช้เพืออธิบายการคำนวณเท่านัน ไม่ใช่ผลสแกนเว็บไซต์จริง)

https://secure-account-login-example.xyz/verify

สมมติว่ากฎต่าง ๆ รวมกันได้ RuleScore = 70 และ Random Forest หลัง calibration ให้ MLScore = 0.92

ขัน	การแทนค่าและผลลัพธ์
1. Fuzzy membership	safe = 0, suspicious = (80-70)/(80-50) = 0.3333, dangerous = (70-55)/(85-55) = 0.5
2. FuzzyScore	[(0x0) + (0.3333x50) + (0.5x100)] / (0 + 0.3333 + 0.5) = 80 หรือ 0.80
3. LearnedFusion	z = -3.0433 - 0.3361(0.80) + 6.4386(0.92) = 2.6113
4. Sigmoid	1 / (1 + exp(-2.6113)) = 0.9316 จึงได้คะแนนก่อน Guardrail = 93.16
5. Guardrail	0.80 ≥ 0.50 และ 0.92 ≥ 0.90 จึงเข้า warning consensus และยกคะแนนขันต่ำเป็น 0.99

FinalScore = 100 x 0.99 = 99

ผลลัพธ์: ระบบจัดอยู่ในระดับ warn เพราะคะแนน 99 สูงกว่า WarningThreshold 96 แต่ยังไม่ถึง BlockingThreshold 100

7. ลำดับการทำงานโดยย่อ

URL	RuleScore	FuzzyScore	MLScore	Fusion	Guardrail
รับลิงก์	กฎตรวจ URL	แปลงกฎแบบ fuzzy	Random Forest	Logistic Regression	Allow / Warn / Block

8. ข้อควรเข้าใจเมื่อนำไปอธิบาย

- สูตรนี้ตั้งใจให้ Rule-based และ ML ตรวจร่วมกัน แต่ทั้งสองส่วนยังใช้โครงสร้าง URL เดียวกัน จึงไม่ใช่หลักฐานอิสระทั้งหมด
- FuzzyScore เป็นการแปลง RuleScore ไม่ใช่โมเดลใหม่อีกตัวหนึ่ง
- ConsensusGuardrail สามารถทำให้คะแนนกระโดดเป็น 99 หรือ 100 เมื่อสองคะแนนสูงพร้อมกัน
- คะแนน 99 ไม่ได้หมายความว่าเว็บไซต์เป็น phishing แน่นอน 99% เพราะมีการบังคับ score floor จาก policy
- ตัวอย่างนี้ใช้ค่าที่สมมติขึ้นเพื่อแสดงวิธีคำนวณ ผลจริงต้องให้ระบบสกัด RuleScore และ MLScore จาก URL ที่รับเข้ามา

สรุป

สูตรปัจจุบันประกอบด้วย 4 ขั้น: RuleScore → FuzzyScore + MLScore → LearnedFusion → ConsensusGuardrail ก่อนเปลี่ยนเป็นคะแนน 0-100 และเทียบ Threshold เพื่อเลือก allow, warn หรือ block สูตรมีจุดเด่นด้านการอธิบายหลายชั้น แต่มีความซับซ้อนและอาจทำให้คะแนนกระจุกที่ 99-100